МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №2
по курсу «Программирование графических процессоров»

Обработка изображений на GPU. Фильтры.

Выполнил: А. О. Тояков
Группа: М8О-407Б-18
Преподаватели: К. Г. Крашенинников,
А. Ю. Морозов

Москва, 2021

УСЛОВИЕ

Цель работы: научится использовать GPU для обработки изображений. Использование текстурной памяти.

Формат изображений. Изображение является бинарным файлом, со следующей структурой:

width(w)	height(h)	r	g	b	a	r	g	b	a	r	g	b	a	...	r	g	b	a	r	g	b	a
4 байта, int	4 байта, int	4 байта, значение пикселя [1,1]				4 байта, значение пикселя [2,1]				4 байта, значение пикселя [3,1]				...	4 байта, значение пикселя [w - 1, h]				4 байта значение пикселя [w,h]			

В первых восьми байтах записывается размер изображения, далее построчно все значения пикселей, где

- r -- красная составляющая цвета пикселя
- g -- зеленая составляющая цвета пикселя
- b -- синяя составляющая цвета пикселя
- a -- значение альфа-канала пикселя

Пример картинки размером 2 на 2, синего цвета, в шестнадцатеричной записи:

```
02000000 02000000 0000FF00 0000FF00 0000FF00 0000FF00
```

Студентам предлагается самостоятельно написать конвертер на *любом* языке программирования для работы с вышеописанным форматом.

В данной лабораторной работе используются только цветовые составляющие изображения (r g b), альфа-канал не учитывается. При расчетах значений допускается ошибка в ±1. Ограничение: $w < 2^{16}$ и $h < 2^{16}$. Во всех вариантах, кроме 2-го и 4-го, в пограничном случае, необходимо “расширять” изображение за его границы, при этом значения соответствующих пикселей дублируют граничные. То есть, для любых индексов i и j, координаты пикселя [ip, jp] будут определятся следующим образом:

```
ip := max(min(i, h), 1)
jp := max(min(j, w), 1)
```

.

Вариант 5. Выделение контуров. Метод Робертса.

Входные данные. На первой строке задается путь к исходному изображению, на второй, путь к конечному изображению. $w*h \leq 10^8$.

Пример:

Входной файл	hex: in.data	hex: out.data
in.data out.data	03000000 03000000 01020300 04050600 07080900 09080700 06050400 03020100 00000000 14141400 00000000	03000000 03000000 04040400 03030300 07070700 0C0C0C00 12121200 03030300 1C1C1C00 1C1C1C00 00000000
in.data out.data	03000000 03000000 00000000 00000000 00000000 00000000 80808000 00000000 00000000 00000000 00000000	03000000 03000000 80808000 80808000 00000000 80808000 80808000 00000000 00000000 00000000 00000000

ПРОГРАММНОЕ И АППАРАТНОЕ ОБЕСПЕЧЕНИЕ

Device: GeForce MX250

Размер глобальной памяти: 3150381056

Размер константной памяти : 65536

Размер разделяемой памяти: 49152

Регистров на блок: 32768

Максимум потоков на блок: 1024

Количество мультипроцессоров : 3

OS: Linux Ubuntu 18.04

Редактор: VSCode

Компилятор: nvcc версии 11.4 (g++ версии 7.5.0)

МЕТОД РЕШЕНИЯ

Для реализации метода Робертса необходимо вычислить яркость пикселя (i, j, где i и j – координаты равные номерам потока сетки по idx и idy), а также трёх соседних с координатами (i + 1, j), (i, j + 1) и (i + 1, j + 1). Учитывая, что интерфейс текстурной ссылки предусматривает выход за границы, нам об этом не нужно беспокоиться. Затем посчитать разности 2 пар яркостей (4 и 1, 2 и 3). Результирующая яркость res будет вычислять как корень квадратный из суммы квадратов этих разностей и если она будет > 255, то необходимо приравнять её к 255. После чего в результирующий массив out мы запишем точку (res, res, res, 255) по координатам: номер потока в сетке по y * ширину картинки + номер потока в сетке по x. Потоки будут обрабатывать по несколько элементов сразу, используя переменные offsetx и offsety, как шаг. Затем нужно передать готовый массив обратно хосту и вывести результат в бинарный файл.

ОПИСАНИЕ ПРОГРАММЫ

Макрос **CSC** отвечает за отслеживание ошибок в функциях cuda, поэтому все cuda-вызовы оборачиваются в него и при cudaError_t != cudaSuccess выводится сообщение об ошибке.

Texture<uchar4, 2, cudaReadModeElementType> tex – текстурная ссылка, которая будет использоваться для работы с данными которая имеет три параметра <тип данных, размерность, режим нормализации>

__global__ void kernel(int* arr, n) – функция на GPU, в которой происходит обработка массива по потокам.

__device__ uchar4 get_pixel(int i, int j) – функция на GPU, которая позволяет получить пиксель из данных, хранящихся в текстурной ссылке.

__device__ double brightness(uchar4 pixel) – функция на GPU, которая расчитывает яркость пикселя, поданного на вход по формуле 0.299 * x + 0.587 * y + 0.114 * z

int main() – отвечает за ввод, передачу данных в kernel и вывод.

ПРИМЕРЫ РАБОТЫ ПРОГРАММЫ

До обработки:

После обработки:

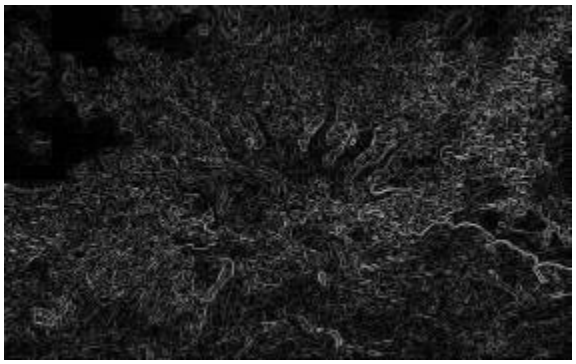

ТЕСТЫ ПРОИЗВОДИТЕЛЬНОСТИ

Для обеих программ данные генерировались рандомно. Изменялись только размеры картинки и конфигурации ядер. Работа на GPU:

Тест:	Результат:
10 * 10	kernel = «<1, 32»>, time = 0.028128 kernel = «<1, 64»>, time = 0.015296 kernel = «<1, 128»>, time = 0.015296 kernel = «<1, 256»>, time = 0.014336 kernel = «<1, 512»>, time = 0.013248 kernel = «<1, 1024»>, time = 0.015360 kernel = «<2, 32»>, time = 0.014336 kernel = «<2, 64»>, time = 0.013312 kernel = «<2, 128»>, time = 0.012288 kernel = «<2, 256»>, time = 0.012288 kernel = «<2, 512»>, time = 0.013312 kernel = «<2, 1024»>, time = 0.013312 kernel = «<4, 32»>, time = 0.013312 kernel = «<4, 64»>, time = 0.014176 kernel = «<4, 128»>, time = 0.014336 kernel = «<4, 256»>, time = 0.015360 kernel = «<4, 512»>, time = 0.017408 kernel = «<4, 1024»>, time = 0.012288 kernel = «<8, 32»>, time = 0.012288 kernel = «<8, 64»>, time = 0.012288 kernel = «<8, 128»>, time = 0.012288 kernel = «<8, 256»>, time = 0.017408 kernel = «<8, 512»>, time = 0.015360 kernel = «<8, 1024»>, time = 0.015360 kernel = «<16, 32»>, time = 0.014336 kernel = «<16, 64»>, time = 0.014336 kernel = «<16, 128»>, time = 0.014336 kernel = «<16, 256»>, time = 0.012288 kernel = «<16, 512»>, time = 0.014336 kernel = «<16, 1024»>, time = 0.015296 kernel = «<32, 32»>, time = 0.014336 kernel = «<32, 64»>, time = 0.015200

	kernel = «<32, 128»>, time = 0.013312 kernel = «<32, 256»>, time = 0.017408 kernel = «<32, 512»>, time = 0.015360 kernel = «<32, 1024»>, time = 0.019360 kernel = «<64, 32»>, time = 0.015360 kernel = «<64, 64»>, time = 0.017408 kernel = «<64, 128»>, time = 0.015264 kernel = «<64, 256»>, time = 0.017280 kernel = «<64, 512»>, time = 0.017408 kernel = «<64, 1024»>, time = 0.028672 kernel = «<128, 32»>, time = 0.014336 kernel = «<128, 64»>, time = 0.014336 kernel = «<128, 128»>, time = 0.016384 kernel = «<128, 256»>, time = 0.015360 kernel = «<128, 512»>, time = 0.028672 kernel = «<128, 1024»>, time = 0.049152 kernel = «<256, 32»>, time = 0.017408 kernel = «<256, 64»>, time = 0.015360 kernel = «<256, 128»>, time = 0.015360 kernel = «<256, 256»>, time = 0.028576 kernel = «<256, 512»>, time = 0.048128 kernel = «<256, 1024»>, time = 0.097280 kernel = «<512, 32»>, time = 0.017408 kernel = «<512, 64»>, time = 0.015360 kernel = «<512, 128»>, time = 0.026624 kernel = «<512, 256»>, time = 0.048128 kernel = «<512, 512»>, time = 0.092160 kernel = «<512, 1024»>, time = 0.187360 kernel = «<1024, 32»>, time = 0.021504 kernel = «<1024, 64»>, time = 0.025600 kernel = «<1024, 128»>, time = 0.050176 kernel = «<1024, 256»>, time = 0.096256 kernel = «<1024, 512»>, time = 0.183296 kernel = «<1024, 1024»>, time = 0.364544
100 * 100	kernel = «<1, 32»>, time = 0.415200 kernel = «<1, 64»>, time = 0.249856 kernel = «<1, 128»>, time = 0.116672 kernel = «<1, 256»>, time = 0.116704 kernel = «<1, 512»>, time = 0.116736 kernel = «<1, 1024»>, time = 0.116736 kernel = «<2, 32»>, time = 0.249856 kernel = «<2, 64»>, time = 0.115712 kernel = «<2, 128»>, time = 0.115712 kernel = «<2, 256»>, time = 0.115712 kernel = «<2, 512»>, time = 0.115744 kernel = «<2, 1024»>, time = 0.116736 kernel = «<4, 32»>, time = 0.116736 kernel = «<4, 64»>, time = 0.115712 kernel = «<4, 128»>, time = 0.116736 kernel = «<4, 256»>, time = 0.115712 kernel = «<4, 512»>, time = 0.116736 kernel = «<4, 1024»>, time = 0.117760 kernel = «<8, 32»>, time = 0.115712 kernel = «<8, 64»>, time = 0.091136 kernel = «<8, 128»>, time = 0.115712 kernel = «<8, 256»>, time = 0.113664 kernel = «<8, 512»>, time = 0.115712 kernel = «<8, 1024»>, time = 0.119776 kernel = «<16, 32»>, time = 0.122752

	kernel = «<16, 64»>, time = 0.118784 kernel = «<16, 128»>, time = 0.119808 kernel = «<16, 256»>, time = 0.120832 kernel = «<16, 512»>, time = 0.128000 kernel = «<16, 1024»>, time = 0.126976 kernel = «<32, 32»>, time = 0.097280 kernel = «<32, 64»>, time = 0.120832 kernel = «<32, 128»>, time = 0.125952 kernel = «<32, 256»>, time = 0.124928 kernel = «<32, 512»>, time = 0.130048 kernel = «<32, 1024»>, time = 0.130048 kernel = «<64, 32»>, time = 0.101376 kernel = «<64, 64»>, time = 0.113664 kernel = «<64, 128»>, time = 0.120832 kernel = «<64, 256»>, time = 0.133120 kernel = «<64, 512»>, time = 0.147456 kernel = «<64, 1024»>, time = 0.184320 kernel = «<128, 32»>, time = 0.108544 kernel = «<128, 64»>, time = 0.118784 kernel = «<128, 128»>, time = 0.133120 kernel = «<128, 256»>, time = 0.139296 kernel = «<128, 512»>, time = 0.179200 kernel = «<128, 1024»>, time = 0.356352 kernel = «<256, 32»>, time = 0.119648 kernel = «<256, 64»>, time = 0.125952 kernel = «<256, 128»>, time = 0.130080 kernel = «<256, 256»>, time = 0.180224 kernel = «<256, 512»>, time = 0.348160 kernel = «<256, 1024»>, time = 0.687104 kernel = «<512, 32»>, time = 0.104448 kernel = «<512, 64»>, time = 0.138240 kernel = «<512, 128»>, time = 0.179200 kernel = «<512, 256»>, time = 0.345088 kernel = «<512, 512»>, time = 0.686080 kernel = «<512, 1024»>, time = 1.375232 kernel = «<1024, 32»>, time = 0.126976 kernel = «<1024, 64»>, time = 0.182272 kernel = «<1024, 128»>, time = 0.344064 kernel = «<1024, 256»>, time = 0.678912 kernel = «<1024, 512»>, time = 1.349632 kernel = «<1024, 1024»>, time = 3.923968
1000 * 1000	kernel = «<1, 32»>, time = 27.872671 kernel = «<1, 64»>, time = 13.858816 kernel = «<1, 128»>, time = 10.720256 kernel = «<1, 256»>, time = 8.166400 kernel = «<1, 512»>, time = 6.575104 kernel = «<1, 1024»>, time = 6.896640 kernel = «<2, 32»>, time = 15.527968 kernel = «<2, 64»>, time = 11.299840 kernel = «<2, 128»>, time = 4.594688 kernel = «<2, 256»>, time = 5.416960 kernel = «<2, 512»>, time = 3.768320 kernel = «<2, 1024»>, time = 8.294432 kernel = «<4, 32»>, time = 12.028928 kernel = «<4, 64»>, time = 4.701184 kernel = «<4, 128»>, time = 3.727264 kernel = «<4, 256»>, time = 3.980288 kernel = «<4, 512»>, time = 3.243008 kernel = «<4, 1024»>, time = 6.144000

	kernel = «<8, 32»>, time = 3.879936 kernel = «<8, 64»>, time = 3.751936 kernel = «<8, 128»>, time = 2.112512 kernel = «<8, 256»>, time = 3.913728 kernel = «<8, 512»>, time = 2.985984 kernel = «<8, 1024»>, time = 5.609472 kernel = «<16, 32»>, time = 4.930560 kernel = «<16, 64»>, time = 2.072576 kernel = «<16, 128»>, time = 2.066432 kernel = «<16, 256»>, time = 4.213760 kernel = «<16, 512»>, time = 3.980288 kernel = «<16, 1024»>, time = 5.898240 kernel = «<32, 32»>, time = 2.071552 kernel = «<32, 64»>, time = 2.066432 kernel = «<32, 128»>, time = 2.073600 kernel = «<32, 256»>, time = 3.745792 kernel = «<32, 512»>, time = 2.837504 kernel = «<32, 1024»>, time = 5.965760 kernel = «<64, 32»>, time = 2.066432 kernel = «<64, 64»>, time = 2.072576 kernel = «<64, 128»>, time = 2.091008 kernel = «<64, 256»>, time = 3.447808 kernel = «<64, 512»>, time = 3.103744 kernel = «<64, 1024»>, time = 5.478400 kernel = «<128, 32»>, time = 2.065408 kernel = «<128, 64»>, time = 2.091008 kernel = «<128, 128»>, time = 2.115552 kernel = «<128, 256»>, time = 2.802688 kernel = «<128, 512»>, time = 4.364288 kernel = «<128, 1024»>, time = 6.580224 kernel = «<256, 32»>, time = 2.075648 kernel = «<256, 64»>, time = 2.116608 kernel = «<256, 128»>, time = 2.153472 kernel = «<256, 256»>, time = 3.445760 kernel = «<256, 512»>, time = 3.566592 kernel = «<256, 1024»>, time = 10.571776 kernel = «<512, 32»>, time = 2.104320 kernel = «<512, 64»>, time = 2.189280 kernel = «<512, 128»>, time = 3.591168 kernel = «<512, 256»>, time = 3.526656 kernel = «<512, 512»>, time = 7.270400 kernel = «<512, 1024»>, time = 14.372864 kernel = «<1024, 32»>, time = 2.094080 kernel = «<1024, 64»>, time = 2.504704 kernel = «<1024, 128»>, time = 3.403776 kernel = «<1024, 256»>, time = 6.112256 kernel = «<1024, 512»>, time = 16.571392 kernel = «<1024, 1024»>, time = 34.676735

Работа на CPU:

Тест:	Результат:
10 * 10	0.072
100 * 100	4.623

1000 * 1000	100.242

Как можно заметить на самом маленьком тесте программа на GPU даёт совсем не существенный выигрыш в скорости, а при выборе количества блоков и потоков > 1024 вообще проигрывает по времени. На среднем и большом тестах распараллеливание даёт большой выигрыш в скорости работы, однако указывать параметры ядра очень большими снова нецелесообразно.

ВЫВОДЫ

Сделав вторую лабораторную работу, я узнал основы использования текстурной памяти и её особенности. Для начала скажу, что мне достался вариант № 5 – метод Робертса, который совсем прост в реализации. Используя пример с лекции, мне было легко разобраться с тем, как получать данные по текстурной ссылке. Для работы с текстурами нужно сначала записать данные в CUDA структуру cuda_Array. Затем настроить интерфейс текстурной ссылки, где будут учтены и обработаны следующие параметры:

1. Обработка выхода за границы по каждому измерению, что сильно облегчает реализацию алгоритма. CUDA сама видит, попадает ли точка в заданный отрезок и если нет, то проводит преобразование.
2. Фильтрация данных, а именно, когда адрес и данные разных типов и непонятно какое значение возвращать из текстуры, CUDA выполняет один из способов: Point – берёт ближайшее значение из массива или Linear – значение берётся после выполнения линейной интерполяции.
3. Нормализация координат – переводит заданный отрезок в отрезок [0, 1].

После того, как интерфейс будет настроен, нам нужно привязать его к данным с помощью команды cudaBindTextureToArray. Теперь можно работать с текстурной ссылкой на девайсе.

Я думаю, что использовать технологию CUDA для обработки изображений фильтрами не очень эффективно, особенно на больших данных,

т. к. частое обращение к памяти сильно замедляет программу. Гораздо лучше параллелить на видеокарте какие-нибудь нейросети. Однако, исходя из тестов производительности, на маленьких картинках программа на GPU имеет преимущество. В целом было интересно реализовывать эту программу, т. к. можно было наблюдать результат сразу же после выполнения, всего лишь конвертировав бинарный файл обратно в pic_name.png.